

Dashboard Analítico de Playlists de Tutoriais de Programação no YouTube

João Augusto Aquino

1. Introdução

Este trabalho apresenta a construção de um dashboard analítico utilizando ferramenta de Business Intelligence para análise de playlists de tutoriais de programação publicadas no YouTube. O objetivo é explorar visualmente os dados coletados no contexto de TIS 6, permitindo identificar padrões de engajamento e abandono (churn) em playlists de diferentes linguagens de programação.

Para a construção do dashboard foi utilizada a ferramenta Google Data Studio, permitindo a criação de gráficos interativos, tabelas descritivas e métricas agregadas para apoiar a interpretação dos resultados experimentais.

O dataset utilizado é composto por playlists de tutoriais de programação coletadas no YouTube, contendo métricas relacionadas ao tamanho das playlists, engajamento dos vídeos e comportamento de abandono dos espectadores.

2. Metodologia

Os dados utilizados foram extraídos e processados previamente em TIS 6, sendo organizados em arquivos CSV contendo métricas de playlists e vídeos individuais.

Neste laboratório foi utilizado principalmente o arquivo **playlist_metrics.csv**, contendo métricas agregadas por playlist. Entre os atributos analisados destacam-se:

- **language**: linguagem de programação da playlist;
- **playlist_size**: quantidade de vídeos;
- **size_bucket**: categorização do tamanho da playlist;
- **mean_signal**: métrica de engajamento médio;
- **median_signal**: mediana do engajamento;
- **has_churn**: indicação de ocorrência de abandono;
- **churn_position_normalized**: posição normalizada em que ocorre churn.

Para análise visual foi utilizada a ferramenta Google Looker Studio, permitindo a construção de dashboards interativos com gráficos de barras, gráficos de pizza, tabelas descritivas e filtros dinâmicos.

A análise foi dividida em duas questões de pesquisa:


- **RQ1**: Como o engajamento varia entre diferentes linguagens de programação?
- **RQ2**: Em que ponto das playlists os espectadores abandonam o conteúdo?

3. Caracterização do Dataset

O dataset analisado contém 572 playlists distribuídas entre 10 linguagens de programação diferentes.

As linguagens mais representadas foram Python (83 playlists), Java (76) e C++ (71), enquanto Go apresentou a menor quantidade de playlists (26). A Figura 1 apresenta a distribuição das playlists por linguagem.

Quantidade de Playlists por Linguagem




Além disso, as playlists foram categorizadas em três grupos de tamanho:

- Pequenas (até 9 vídeos);
- Médias (10 a 30 vídeos);
- Grandes (mais de 30 vídeos).

Observou-se predominância de playlists médias, representando aproximadamente metade do dataset total. A Figura 2 apresenta a distribuição por tamanho.

Distribuição por Tamanho de Playlist



Também foram calculadas estatísticas descritivas por linguagem, incluindo mediana de engajamento e taxa de churn. A Tabela 1 mostra que Java apresentou a maior mediana de engajamento entre as linguagens analisadas, enquanto Go apresentou os menores valores médios.

Estatísticas Descritivas por Linguagem

	language	N	Mediana En...	Com Churn
1.	java	76	0	76
2.	cplusplus	71	0	71
3.	python	83	0	83
4.	javascript	62	0	62
5.	php	67	0	67
6.	c	57	0	57
7.	typescript	32	0	32
8.	shell	27	0	27
9.	csharp	71	0	71
10.	go	26	0	26

1 - 10 / 10 < >

De forma geral, o dataset apresenta alta incidência de churn, com taxas superiores a 96% em praticamente todas as linguagens.

4. Resultados

4.1 RQ1 - Engajamento entre linguagens


A primeira questão de pesquisa buscou avaliar como o engajamento varia entre diferentes linguagens de programação.

Os resultados mostram que linguagens como Java, C++ e JavaScript apresentaram maiores medianas de engajamento, indicando maior retenção e interação dos usuários nas playlists dessas categorias.


Por outro lado, linguagens como Go, Shell e TypeScript apresentaram menores valores de engajamento mediano.

Foi utilizada a mediana ao invés da média devido à distribuição assimétrica dos dados e à presença de muitos valores próximos de zero, tornando a mediana mais representativa do comportamento geral do dataset.

Também foi observada relação entre tamanho da playlist e engajamento. Playlists menores apresentaram níveis ligeiramente superiores de engajamento quando comparadas às playlists grandes.



RQ1 - Gráfico de Barras Agrupadas: Engajamento por Linguagem × Tamanho



4.2 RQ2 - Análise de churn

A segunda questão de pesquisa investigou o comportamento de abandono dos espectadores ao longo das playlists.


Os resultados mostram taxas extremamente elevadas de churn, próximas de 100% em praticamente todas as linguagens analisadas. Isso indica que o abandono de playlists é um comportamento recorrente independentemente da linguagem de programação.

Em relação à posição do churn, observou-se mediana próxima ao meio das playlists (~0.52 na posição normalizada). Isso sugere que os usuários


tendem a abandonar o conteúdo aproximadamente na metade do percurso da playlist.

Também foi possível observar que playlists maiores tendem a apresentar churn ligeiramente mais cedo quando comparadas às playlists pequenas.

RQ2: Taxa de Churn por Linguagem



RQ2: Posição de Churn por Tamanho de Playlist



5. Conclusão

O dashboard desenvolvido permitiu explorar visualmente características relevantes do dataset e responder às questões de pesquisa propostas.

Os resultados indicam diferenças de engajamento entre linguagens de programação e evidenciam altas taxas de abandono em playlists de tutoriais no YouTube.

Além disso, o uso de ferramentas de Business Intelligence mostrou-se eficiente para organização, visualização e interpretação dos dados experimentais, tornando o processo analítico mais claro e interativo.

Como trabalho futuro, seria interessante ampliar o dataset e incorporar métricas temporais, duração dos vídeos e padrões de progressão dos usuários ao longo das playlists.